Klasifikasi Citra Masakan Tradisional Nusantara dengan Model SigLIP2 Berbasis Linear-Probe

Nama Tim : ClusTerra

Anggota Tim : 1. Anwar Rohmadi

2. Ahmad Ruhayani Azis

3. Deanova Cella Fadila

ABSTRAK

Klasifikasi citra makanan tradisional memainkan peran penting dalam pelestarian dan promosi keragaman kuliner Nusantara. Penelitian ini mengusulkan solusi berbasis SigLIP2, sebuah model vision-language multilingual yang dilatih dengan jutaan pasangan gambar-teks, sebagai feature extractor untuk membangun pengklasifikasi linier. Dengan membekukan parameter backbone SigLIP2 dan melatih lapisan linier di atas representasi fitur yang dihasilkan (teknik yang dikenal sebagai linear probing), kami berupaya memanfaatkan kemampuan representasi tinggi dari model pralatih tanpa biaya komputasi besar dari fine-tuning penuh. Dataset terdiri atas 15 kelas makanan Indonesia (misal: Ayam Bakar, Bakso, Rendang), masing-masing ratusan citra yang dikumpulkan dari Kaggle. Kami menambahkan masker semantik yang dihasilkan otomatis untuk menyorot area objek makanan utama. Hasil evaluasi menujukkan bahwa pendekatan ini mencapai akurasi top-1 sebesar 89,87 % dan top-5 sebesar 99,49 % pada data validasi, dengan skor F1 makro 0,898 dan area di bawah kurva ROC rata-rata 0,975. Penelitian ini juga menganalisis kontribusi penggunaan masker terhadap performa dan menggambarkan distribusi kesalahan antara kelas. Analisis menyarankan bahwa meskipun cakupan pasangan masker masih rendah (3,3 %), integrasi masker serta ekstraksi fitur SigLIP2 memberikan peningkatan kinerja yang berarti dibandingkan metode pengklasifikasi tradisional.

Keyword: *Klasifikasi Citra Makanan, Masakan Nusantara, SigLIP2, Linear Probing, Vision-Language Models, Ekstraksi Fitur, Segmentasi Semantik*

PENDAHULUAN

Kekayaan kuliner Indonesia tercermin melalui keberagaman makanan tradisional dari berbagai daerah. Mengklasifikasikan citra makanan tersebut secara otomatis membantu pengarsipan digital, rekomendasi kuliner, dan aplikasi kesehatan. Klasifikasi makanan merupakan tantangan karena variasi bentuk, tekstur, latar belakang, dan kondisi pencahayaan. Model visi klasik berbasis CNN memerlukan sejumlah besar anotasi yang spesifik untuk setiap kelas, sementara pendekatan *vision-language* modern seperti CLIP dan SigLIP mempelajari representasi visual dari jutaan pasangan gambar-teks, memungkinkan generalisasi yang lebih baik. SigLIP2, turunan terbaru dari SigLIP, memperluas tujuan pelatihan dengan menggabungkan teknik captioning, *self-distillation*, dan *masked prediction* ke dalam satu resep sehingga meningkatkan pemahaman semantik dan representasi padat[1]. Perbaikan tersebut menghasilkan peningkatan signifikan pada tugas klasifikasi nol-tembakan, pengambilan gambar-teks, dan ekstraksi fitur untuk model vision-language[1]. Model ini dilatih pada dataset WebLI yang beraneka ragam, mencakup miliaran pasangan gambar-teks dari berbagai bahasa dan budaya[2].

Kendati model pralatih kuat tersedia, penyesuaian untuk tugas tertentu masih diperlukan. Dua strategi umum adalah *fine-tuning* penuh dan *linear probing*. *Fine-tuning* memperbarui seluruh parameter model pada dataset baru, namun mahal secara komputasi terutama untuk model berparameter miliaran. Sebaliknya, *linear probing* membekukan model pralatih dan melatih pengklasifikasi linier di atas representasi fitur. Snorkel AI menjelaskan bahwa *linear probing* menahan model tetap dan hanya melatih model kecil di atas fitur, sedangkan *fine-tuning* memperbarui semua parameter melalui penurunan gradien[3]. Teknik ini efisien karena tidak membutuhkan propagasi balik melalui backbone dan sering menjadi pilihan awal sebelum *fine-tuning*[4].

Penelitian ini fokus pada klasifikasi citra 15 jenis masakan Nusantara dengan memanfaatkan kemampuan representasi SigLIP2 dan strategi *linear probing*. Kami juga menyelidiki penggunaan masker semantik yang diperoleh dari model segmentasi untuk memusatkan perhatian pada wilayah makanan utama. Hasil kami menunjukkan bahwa penggabungan SigLIP2 dengan pengklasifikasi linier dapat mencapai performa tinggi dengan sumber daya komputasi relatif rendah. Laporan ini disusun menjadi beberapa bagian: studi literatur, usulan solusi, metode penelitian, hasil dan analisis, serta kesimpulan.

STUDI LITERATUR

Vision-Language Models

Model *vision-language* menjadi landasan banyak aplikasi visi modern. CLIP (Contrastive Language Image Pre-training) yang diperkenalkan oleh Radford et al. mempelajari representasi visual melalui prediksi pasangan gambar-caption pada lebih dari 400 juta sampel[5]. Setelah

pre-training, model ini dapat memanfaatkan deskripsi alami untuk melakukan klasifikasi nol-tembakan di berbagai dataset tanpa pelatihan ulang. CLIP memperlihatkan bahwa pre-training dengan data skala besar memungkinkan transfer yang kompetitif dibanding model yang dilatih secara terawasi[5].

SigLIP (Sign Language Image Pre-training) merupakan varian CLIP yang mengganti fungsi kerugian *contrastive* dengan kerugian *signed logit*. Iterasi kedua, SigLIP2, menambahkan tujuan pelatihan tambahan berupa kerugian captioning, *self-distillation*, dan prediksi bertopeng, serta kurasi data aktif[1]. Model ini mampu menghasilkan fitur padat yang bermanfaat untuk lokalisasi objek dan prediksi kepadatan[1]. SigLIP2 dilatih menggunakan dataset WebLI yang mencakup data multibahasa dan dilaporkan meningkatkan kemampuan multibahasa dan keadilan model[2].

Linear Probing dan Fine-Tuning

Linear probing adalah teknik evaluasi representasi di mana model pralatih dibekukan dan sebuah pengklasifikasi linier dilatih di atas fitur internalnya. Konsep ini digunakan untuk menilai seberapa mudah fitur dapat dipisahkan secara linear. Menurut Snorkel AI, linear probing melatih model kecil di atas keluaran fitur tanpa memperbarui backbone; sebaliknya *fine-tuning* memperbarui semua parameter dan karenanya lebih mahal[3]. Linear probing dinilai efisien karena tidak memerlukan propagasi gradien melalui model besar[4]. Studi lain menunjukkan bahwa linear probing sering digunakan sebagai langkah awal sebelum fine-tuning penuh, khususnya untuk dataset berukuran sedang.

Klasifikasi Makanan Tradisional

Penelitian mengenai klasifikasi makanan tradisional Nusantara masih terbatas. Rangkuti et al. mengidentifikasi 34 jenis makanan Indonesia menggunakan berbagai metode segmentasi (Sobel, Prewitt, Robert, Scharr, Canny) dan algoritme pembelajaran mesin seperti Random Forest, Decision Tree, dan SVM. Hasilnya menunjukkan bahwa Random Forest dengan segmentasi Robert mencapai akurasi 85,52 % dengan skor F1 82,49 %, sedangkan kombinasi lain mencapai akurasi antara 78-85 %[6]. Studi tersebut menyoroti pentingnya tahap segmentasi dalam meningkatkan akurasi klasifikasi makanan.

Sebagian dataset masakan Indonesia telah tersedia di Kaggle dan platform lainnya, tetapi banyak di antaranya masih kecil dan kurang beragam. Penggunaan model pralatih besar yang telah mempelajari konsep visual umum diharapkan meningkatkan kinerja pada dataset dengan data terbatas.

Solusi dan Usulan

Kami mengusulkan pendekatan klasifikasi citra masakan Nusantara menggunakan model SigLIP2 sebagai *feature extractor* dan pengklasifikasi linier sebagai *head*. Pendekatan ini memanfaatkan representasi kuat dari model vision-language yang dilatih secara kontrastif dengan data besar sambil menjaga efisiensi melalui pembekuan parameter backbone. Langkah-langkah utama solusi ini meliputi:

1. Ekstraksi Fitur SigLIP2: Memuat model SigLIP2 google/siglip2-giant-opt-patch16-384 dari Hugging Face, membekukan parameternya (requires_grad=False) dan menjalankannya pada citra terproses untuk memperoleh vektor fitur berdimensi 1536.
2. Penggunaan Masker Semantik: Memanfaatkan masker segmentasi semantik (dari dataset MASK_ROOT) untuk menyorot area makanan. Kami menerapkan tiga mode: crop (memotong citra pada area mask), multiply (mengalikan piksel dengan mask), dan dual (menggunakan kedua versi sebagai tampilan ganda). Strategi binarisasi mask mengikuti kategori target (MASK_BIN_STRATEGY="target"), sehingga hanya piksel dengan label mask yang sesuai kelas dipertahankan.
3. Linear Head: Merancang lapisan linier berukuran feat_dim × 15 (jumlah kelas) yang diawali dengan normalisasi lapisan (LayerNorm) untuk menstabilkan distribusi fitur. Kepala ini dilatih menggunakan *cross-entropy loss* dan dioptimalkan dengan AdamW berkecepatan belajar 1e-3 dan berat regularisasi 1e-4.
4. Strategi Augmentasi dan Split: Dataset dipecah menggunakan *StratifiedKFold* lima lipatan untuk menjaga distribusi kelas. Augmentasi meliputi *random resized crop* dan *horizontal flip* untuk meningkatkan keragaman data. Early stopping digunakan dengan ketabahan 5 epoch dan ambang peningkatan minimal 0,002 untuk mencegah overfitting.
5. Evaluasi dan Metrik: Kinerja dinilai menggunakan akurasi top-1 dan top-5, skor F1 makro dan berbobot, *balanced accuracy*, area di bawah kurva ROC (macro ROC-AUC), serta *average precision*. Confusion Matrix disusun untuk menganalisis distribusi prediksi per kelas. Kami juga menyimpan bobot kepala linier dan *label encoder* agar dapat dimuat ulang tanpa pelatihan ulang.

Selain itu, kami mengevaluasi kontribusi masker dengan menghitung cakupan pasangan antara citra dan mask (MaskPairer). Pelaporan menunjukkan bahwa hanya 3,3 % citra dalam folder pelatihan memiliki pasangan mask yang cocok, baik melalui pencocokan nama berkas maupun pembandingan hash; hal ini memberikan tantangan bagi pemanfaatan penuh mask.

METODE PENELITIAN

Akuisisi Dataset dan Masker Semantik

Dataset dibangun melalui dua alur kerja utama yang diorganisir menggunakan Roboflow:

1. Anotasi Kelas: Total 1.971 citra masakan Nusantara diberi label kelas secara manual. Dataset ini kemudian dibagi menjadi 1576 citra pelatihan dan 395 citra validasi. (2.057 citra uji dari sumber Kaggle digunakan untuk evaluasi akhir). Dataset mencakup 15 kategori: *Ayam Bakar, Ayam Betutu, Ayam Goreng, Ayam Pop, Bakso, Coto Makassar, Gado Gado, Gudeg, Nasi Goreng, Pempek, Rawon, Rendang, Sate Madura, Sate Padang,* dan *Soto*, dengan distribusi kelas yang relatif seimbang (104-163 citra per kelas).
2. Mask Generation (SAM): Sebuah subset dari data pelatihan, sebanyak 633 citra, diproses menggunakan *Segment Anything (SAM)* untuk menghasilkan *semantic mask*. Untuk memastikan kualitas segmentasi yang optimal, 633 citra ini dinormalisasi *sebelum* diproses oleh SAM (Auto-Orient, Resize ke 640x640, dan Kontras Adaptif).

Pra-pemrosesan Model dan Strategi *Dual-View*

Semua 1.971 citra pelatihan (dan 633 *mask* yang sesuai) harus diubah ke format input yang dibutuhkan oleh *backbone* SigLIP2.

1. Ukuran Input Model: Ukuran input akhir untuk model adalah 384x384 piksel. Oleh karena itu, *masker* 640x640 yang telah dibuat sebelumnya di-resize kembali ke 384x384 agar sesuai.
2. Augmentasi: Untuk *training*, augmentasi yang diterapkan adalah RandomResizedCrop(scale=(0.9,1.0)) dan RandomHorizontalFlip(p=0.5). Untuk *validasi* dan *uji*, hanya transformasi Resize (ke 384x384) yang digunakan untuk konsistensi evaluasi.
3. Metodologi *Dual-View* dan *Fallback*: Kami menerapkan modus *dual-view* di mana vektor fitur akhir adalah rata-rata dari dua tampilan. Strategi ini menangani dua skenario berbeda:
    a. Jika masker tersedia (633 citra): Tampilan 1 adalah citra asli, dan Tampilan 2 adalah citra yang telah di-masking (latar belakang disupresi).
    b. Jika masker tidak tersedia (1.338 citra): Strategi *fallback* diterapkan. Tampilan 1 adalah citra asli, dan Tampilan 2 adalah salinan identik dari citra asli. Ini secara efektif melatih model hanya pada fitur gambar asli untuk mayoritas data, sambil mendapatkan *boost* fokus dari data yang di-*masking*.

Ekstraksi Fitur dan Linear Probe

Model SigLIP2 dimuat melalui modul AutoModel dan AutoImageProcessor dari pustaka transformers. Semua parameter backbone dibekukan, dan model diatur ke mode evaluasi (model.eval()). Fungsi backbone_features memanggil model.get_image_features() untuk menghasilkan representasi fitur dengan dimensi 1536 dari tensor piksel terproses. Jika mode masker dual digunakan, dua tampilan citra (ori dan masked) diproses, dan fitur digabung dengan rata-rata.

Lapisan pengklasifikasi (head) terdiri atas LayerNorm(feat_dim) diikuti oleh Linear(feat_dim, num_classes). Kepala ini dilatih selama lima epoch dengan batch size 64 menggunakan optimiser AdamW. Loss fungsinya *cross-entropy*, dan *early stopping* diterapkan berdasarkan akurasi validasi. Skema training/validasi menggunakan *StratifiedKFold* 5 fold; kami melatih pada satu fold (k=1) dan memilih model dengan akurasi validasi terbaik.

Penilaian Kinerja

Setelah pelatihan, kami mengukur performa pada data validasi dan uji. Metrik yang dihitung meliputi:

1. Top-1 Accuracy: proporsi prediksi yang benar. Validasi menghasilkan 89,87 %.
2. Top-5 Accuracy: proporsi dimana label benar termasuk lima label teratas; tercapai 99,49 %.
3. F1 Score (macro dan weighted): rata-rata harmonik antara presisi dan recall; F1 makro 0,898, F1 berbobot 0,899.
4. Balanced Accuracy: rata-rata akurasi antar kelas; 0,899.
5. Macro ROC-AUC: area di bawah kurva ROC rata-rata (one-vs-rest); 0,975.
6. Average Precision (macro): luas kurva presisi recall; 0,962.

Confusion Matrix (tabel 1) menampilkan proporsi prediksi per kelas setelah normalisasi baris. Misalnya, kelas Ayam Bakar memiliki True Positive Rate 0,96, sedangkan kelas Rendang memiliki recall 0,75. Kinerja per kelas (tabel 2) menunjukkan bahwa kelas Gado Gado, Nasi Goreng, Pempek, dan Sate Padang mencapai skor presisi dan recall sempurna (1,0), sedangkan Ayam Goreng dan Coto Makassar sedikit lebih rendah karena beberapa sampel diklasifikasikan sebagai kelas lain.

Tabel 1 : Confusion Matrix Dinormalisasi

Kelas sebenarnya	Ayam Bakar	Ayam Betutu	Ayam Goreng	Ayam Pop	Bakso	Coto Makassar	Gado Gado	Gudeg	Nasi Goreng	Pempek	Rawon	Rendang	Sate Madura	Sate Padang	Soto
Ayam Bakar	0.96	0.00	0.04	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Ayam Betutu	0.07	0.85	0.07	0.05	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.04	0.00	0.00	0.00
Ayam Goreng	0.10	0.10	0.72	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.07	0.00	0.00	0.00
Ayam Pop	0.00	0.05	0.00	0.90	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.05	0.00	0.00	0.00
Bakso	0.00	0.00	0.03	0.00	0.94	0.00	0.00	0.00	0.00	0.00	0.00	0.03	0.00	0.00	0.00
Coto Makassar	0.00	0.00	0.07	0.00	0.00	0.79	0.00	0.00	0.00	0.00	0.03	0.07	0.00	0.00	0.10
Gado Gado	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Gudeg	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00
Nasi Goreng	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00
Pempek	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.96	0.00	0.00	0.00	0.00	0.04
Rawon	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	0.00	0.00	0.00

Rendang	0.00	0.04	0.00	0.08	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.75	0.00	0.00	0.00
Sate Madura	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.03	0.78	0.19	0.00
Sate Padang	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00
Soto	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.88

Tabel 2 : Metrik Per Kelas

Kelas	Presisi	Recall	F1	Support
Ayam Bakar	0,833	0,962	0,893	26
Ayam Betutu	0,821	0,852	0,836	27
Ayam Goreng	0,913	0,724	0,808	29
Ayam Pop	0,950	0,905	0,927	21
Bakso	0,912	0,939	0,925	33
Coto Makassar	0,852	0,793	0,821	29
Gado Gado	1,000	1,000	1,000	25
Gudeg	0,815	1,000	0,898	22
Nasi Goreng	1,000	1,000	1,000	29
Pempek	1,000	0,957	0,978	23
Rawon	0,833	1,000	0,909	30
Rendang	1,000	0,750	0,857	24
Sate Madura	1,000	0,781	0,877	32
Sate Padang	0,769	1,000	0,870	20
Soto	0,880	0,880	0,880	25

Error Analysis

Secara umum, model menunjukkan kinerja tinggi pada sebagian besar kelas. Kelas dengan performa tertinggi (presisi dan recall 1) adalah Gado Gado, Nasi Goreng, Pempek, dan Sate Padang, menunjukkan bahwa representasi SigLIP2 mampu membedakan fitur khas makanan tersebut dengan sangat baik. Kelas Rendang memiliki recall 0,75; sebagian contoh salah diklasifikasikan sebagai Ayam Betutu atau Ayam Pop, mengindikasikan kemiripan visual seperti penggunaan bumbu bersantan. Begitu pula kelas Ayam Goreng menunjukkan recall 0,724 karena beberapa contoh salah dikelompokkan sebagai Ayam Bakar dan Ayam Betutu. Distribusi kesalahan ini konsisten dengan Confusion Matrix (tabel 1).

Analisis cakupan masker menunjukkan bahwa dari 1971 citra pelatihan, hanya 65 citra (3,3 %) yang memiliki mask yang cocok berdasarkan pencocokan nama atau hash. Banyak mask yang tidak ada atau tidak sesuai label misalnya mask untuk beberapa gambar Ayam Betutu memiliki

kelas dominan yang salah. Walau demikian, penggunaan mode dual yang menggabungkan citra asli dan citra termasker sedikit meningkatkan akurasi validasi dibandingkan hanya menggunakan crop (0,901 vs 0,898). Hal ini menunjukkan potensi penggunaan masker lebih lanjut apabila cakupan mask meningkat.

Kami juga menguji model pada 2057 citra uji. Semua prediksi dikompilasi dalam berkas submission_linear_probe.csv yang menyertakan ID gambar dan label prediksi. Contoh hasil menunjukkan model hampir selalu benar misalnya gambar 0101 diklasifikasikan sebagai Bakso dengan kepercayaan 99 %. Hal ini sejalan dengan akurasi top-5 yang mendekati 100 %.

KESIMPULAN

Penelitian ini memperkenalkan pendekatan klasifikasi citra makanan tradisional Nusantara menggunakan model *vision-language* SigLIP2 dengan teknik *linear probing*. Pendekatan ini memungkinkan pemanfaatan representasi visual kuat dari model pralatih besar tanpa memerlukan pelatihan ulang seluruh parameter. Eksperimen menunjukkan bahwa kombinasi SigLIP2 dan kepala linier sederhana mampu mencapai akurasi top-1 89,87 % dan top-5 99,49 %, dengan skor F1 makro 0,898. Secara per kelas, sebagian besar makanan diklasifikasikan dengan presisi dan recall tinggi; beberapa kelas yang mirip secara visual (misalnya Ayam Goreng dan Ayam Bakar) mengalami kebingungan lebih tinggi. Analisis masker semantik menyoroti rendahnya cakupan mask (3,3 %), namun mode dual memberikan sedikit peningkatan performa, sehingga perlu pengembangan teknik segmentasi dan penandaan mask otomatis.

Hasil ini membuktikan bahwa *linear probing* di atas SigLIP2 merupakan pendekatan efektif dan efisien untuk klasifikasi makanan tradisional. Ke depannya, penelitian dapat mengeksplorasi *fine-tuning* ringan (seperti *LoRA* atau *prefix tuning*) untuk meningkatkan akurasi lebih lanjut, memperluas dataset dengan lebih banyak kelas masakan Nusantara, serta memperbaiki modul segmentasi untuk menghasilkan masker yang akurat. Selain itu, integrasi multimodal (gambar-teks) dapat dieksplorasi untuk memperkaya representasi dan interpretabilitas model.

DAFTAR PUSTAKA

[1] M. Tschannen et al., “SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features,” arXiv preprint, Feb 2025[1][7].

[2] A. Radford et al., “Learning Transferable Visual Models From Natural Language Supervision,” arXiv preprint, Feb 2021[5].

[3] A. Rangkuti, J. Kerta, R. Mogot, & V. Athala, “Identification of Indonesian Traditional Foods Using Machine Learning and Supported by Segmentation Methods,” JOIV : International Journal on Informatics Visualization, vol. 8, no. 4, pp. 2324-2335, 2024[6].

[4] Snorkel AI, “Boost foundation model results with linear probing and fine-tuning,” blog post, Apr 2023[3][4].

[5] Hugging Face, “SigLIP 2 Giant Model Card,” accessed Nov 2025[8][2].